

Análise da Influência dos Componentes na Resistência à Compressão do Concreto

1st João Victor Tavares Esteves

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
joaovtesteves2002@alu.ufc.br

2nd Manoel Guilherme Oliveira Ferreira

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
guiferreira29@alu.ufc.br

3rd Rodrigo da Silva Carvalho Maia

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
rodrigomaia@alu.ufc.br

Abstract—Neste artigo, apresentamos uma análise detalhada da resistência à compressão do concreto por meio de técnicas de inteligência computacional. O conjunto de dados consiste em 1030 instâncias, com 9 atributos, incluindo variáveis quantitativas de entrada que representam vários componentes do concreto e a idade do concreto, bem como a variável quantitativa de saída que representa a resistência à compressão do concreto em MPa. O foco deste estudo é investigar as relações entre esses atributos e a resistência à compressão, visando aprimorar nossa compreensão dos fatores que influenciam a resistência do concreto. Para isso, vamos fazer, inicialmente, uma descrição geral do nosso Dataset, em seguida vamos fazer uma série de análises como incondicional monovariada, classe-condicional monovariada, incondicional monovariada e incondicional multivariada. Em complemento à isso, os resultados obtidos conseguem apontar para as relações existentes entre os preditores para a resistência à compressão do concreto.

Index Terms—visualização de dados, *principal component analysis*, análise, concreto

I. INTRODUÇÃO

A resistência à compressão do concreto é um parâmetro fundamental que influencia diretamente a durabilidade e a capacidade de carga das estruturas de concreto [6]. Compreender os fatores que afetam essa propriedade mecânica é crucial para garantir a qualidade e o desempenho das construções. No entanto, a análise desses fatores complexos exige não apenas uma abordagem profunda, mas também um tratamento adequado dos dados brutos.

Nos últimos anos, técnicas de inteligência computacional têm desempenhado um papel significativo na análise e previsão de propriedades do concreto, incluindo a resistência à compressão [4]. Ao explorar grandes conjuntos de dados e aplicar algoritmos avançados, é possível identificar padrões complexos e relações multifacetadas entre os componentes do concreto e sua resistência final. No entanto, antes de qualquer análise, o tratamento adequado dos dados é essencial.

A qualidade dos resultados obtidos está intrinsecamente ligada ao pré-processamento de dados. O tratamento de outliers, a normalização dos valores das variáveis e a identificação e

correção de dados faltantes são etapas cruciais para garantir a integridade das análises. O uso inadequado de dados não tratados pode levar a conclusões distorcidas e previsões imprecisas. Portanto, uma ênfase significativa deve ser dada à preparação dos dados antes de qualquer análise mais aprofundada.

Além disso, a Análise de Componentes Principais (PCA) emerge como uma ferramenta poderosa para a redução da dimensionalidade e a identificação de padrões latentes nos dados. O conjunto de atributos pode conter redundâncias ou multicolinearidades, o que dificulta a interpretação e a análise eficiente. A aplicação de PCA pode permitir uma representação mais compacta dos dados, preservando as informações mais relevantes [1]. Isso não apenas simplifica a análise, mas também pode revelar relações não óbvias entre as variáveis preditoras e a resistência à compressão.

Neste artigo, realizamos uma análise minuciosa da resistência à compressão do concreto, abordando não apenas as relações entre os atributos preditores e a resistência, mas também a importância crucial do tratamento de dados. Além disso, exploramos como a aplicação da PCA pode aprofundar a compreensão dos padrões subjacentes nos dados. Nosso objetivo é fornecer uma abordagem completa que priorize não apenas os resultados finais, mas também a integridade e a robustez do processo analítico.

A seção seguinte deste artigo examina o conjunto de dados e suas características, enquanto a análise monovariada revela as distribuições e propriedades dos atributos preditores. Posteriormente, investigamos como esses atributos variam nas classes de resistência do concreto, aprofundando nossa compreensão dos fatores que afetam a resistência em cenários diversos. Nossa abordagem contribui para a literatura sobre a relação entre os componentes do concreto e a resistência à compressão.

Na seção final, resumimos nossas conclusões, destacamos implicações práticas e exploramos como os insights podem beneficiar a otimização da mistura de concreto e decisões na engenharia civil. Unindo técnicas de inteligência computacional

cional e conhecimento tradicional de materiais, este estudo enriquece a compreensão da resistência do concreto e seu impacto na indústria da construção civil.

II. MÉTODOS

A. Descrição do Dataset

O conjunto de dados que estamos usando, "Concrete Compressive Strength" [7], é composto por 1030 amostras de concreto, coletadas para medir a resistência a compressão. Cada amostra de concreto possui 9 componentes. Além disso, como nesse conjunto não temos classes propriamente ditas, resolvemos separar em subconjuntos de dados de acordo com a coluna "Age" que representa a idade do concreto da seguinte forma [1-29 dias], [29-365 dias]. Vale ressaltar que todas as características foram determinadas em laboratório, as sete primeiras características estão em kg por metro cúbico de mistura, a oitava em dias(1-365) e a nona em megapascals.

Seguem as nove componentes do conjunto de dados:

- 1) Cimento
- 2) Escória de Alto-Forno
- 3) Cinza Volante
- 4) Água
- 5) Superplastificante
- 6) Agregado Graúdo
- 7) Agregado Miúdo
- 8) Idade
- 9) Resistência à Compressão do Concreto

Os oito primeiros preditores são baseados em testes de laboratório como entrada e o último é baseado também em experimentos em laboratórios, porém como saída.

B. Análise incondicional monovariada

A análise monovariada incondicional representa uma etapa fundamental na exploração de um conjunto de dados, permitindo uma observação individual de cada preditor sem a consideração das classes. Essa abordagem busca compreender como cada atributo do conjunto de dados se distribui, fornecendo informações valiosas sobre seu comportamento intrínseco.

Para realizar essa análise, procedemos com a criação de histogramas individuais para cada um dos preditores e também calculamos métricas importantes, como a média incondicional, o desvio padrão e a assimetria para cada um desses atributos. Isso nos permite avaliar a forma e a dispersão das distribuições dos preditores.


Utilizando o conjunto de dados específico deste estudo, conduzimos a análise monovariada incondicional para as 9 características contidas no conjunto de dados. Abaixo, apresentamos os gráficos relevantes acompanhados de análises breves.

Observamos que a maioria dos gráficos exibe assimetria positiva, indicando inclinação à direita nas distribuições. Notavelmente, "Superplastificante", "Escória de Alto-Forno" e "Idade" destacam-se pela assimetria mais acentuada, o que pode afetar a construção de modelos de previsão devido à

sensibilidade a valores extremos. Essa assimetria exige atenção na análise subsequente.


A Figura 1 abaixo ilustra a distribuição desses preditores, destacando suas características assimétricas.

Fig. 1. Distribuições assimétricas da análise incondicional monovariada



Em contra partida, também encontramos algumas características mais simétricas como Água e Resistência à Compressão do Concreto (MPa), ou seja, possuem valores de simetria mais baixos. Podemos visualizar isso na Figura 2

Fig. 2. Distribuições simétricas da análise incondicional monovariada



C. Análise classe-condicional monovariada

Também conhecida como análise univariada de classe condicional, a análise de classe-condicional monovariada compreende a realizar a aplicação dos processos da análise incondicional monovariada para cada classe. Dessa forma, serão feitos os cálculos de médias, desvios padrão, assimetria das features e plotagem de histogramas para as amostras, mas apenas de uma classe de cada vez.


Estas aferições são de extrema importância pois permitem que sejam feitas avaliações das tendências dos preditores levando em consideração a idade do concreto, o que nos permite, inicialmente, entender as particularidades da classe.

De início, antes de realizar os procedimentos de plots dos gráficos, percebemos que a base de dados escolhida não possui

classes definidas. Com isso, selecionamos o preditor idade para dividir nossos dados em duas classes, sendo elas [1-29 Dias] e [29-365 Dias].


Feito isso, realizando o plot de histogramas, percebemos algumas características dos dados para cada classe em particular. Ao analisarmos os gráficos obtidos para a quantidade de agregado graúdo condicionado a idade do concreto, percebemos que na classe [1-29 Dias] há uma distribuição mais balanceada se comparada com a da classe [29-365 Dias], as quais podemos visualizar na figura 3 a seguir.

Fig. 3. Distribuição da feature Agregado Graúdo na análise classe-condicional monovariada




Para a feature “Agregado Miúdo”, temos que, pelas figuras, o comportamento da distribuição da quantidade de agregado miúdo é bem similar a da quantidade de agregado graúdo, havendo apenas uma assimetria maior para a feature analisadas na figura 4 a seguir.

Fig. 4. Distribuição da feature Agregado Miúdo na análise classe-condicional monovariada



Ao selecionarmos a feature “Resistência à Compressão do Concreto (MPa)”, como se pode visualizar na figura 5, a frequência de valores para as duas classes tem uma distribuição bem similar, guardadas proporções, para a resistência à compressão condicionada a idade do concreto.

Fig. 5. Distribuição da feature Resistência à Compressão na análise classe-condicional monovariada




D. Análise incondicional bi-variada

A análise incondicional bi-variada refere-se a uma análise estatística envolvendo o comportamento de dois preditores mutuamente presentes, sendo seu principal objetivo perceber a influencia de uma variável na outra, desconsiderando outras possíveis variáveis que possam influenciar na relação.

Sendo assim, foi-se necessário criar o gráfico de todos os pontos da relação de pares de preditores, que pode ser visto na figura 6. A cor azul representa a classe dos dias [1-29] e a cor vermelha representa a classe dos dias [29-365].


Fig. 6. Gráfico de dispersão de todos os preditores



Através da interação entre as variáveis, é possível avaliar a correlação entre elas, utilizando o coeficiente de Pearson para medir a correlação linear. O coeficiente varia de +1 a -1, onde +1 indica uma correlação positiva perfeita, -1 uma correlação negativa perfeita. Um valor de correlação de 0 indica ausência de relação entre as variáveis.


Para facilitar a visualização das relações entre os pares de preditores, criamos um mapa de calor das correlações, como mostrado na Figura 7.

Fig. 7. Correlação Linear de todos os preditores




Fazendo a análise dos valores obtidos, ampliamos alguns dos gráficos que se destacam, sendo esses os que se aproximam dos valores explicitados anteriormente. Foram separados 4 exemplos, dois deles são casos que se aproximam dos extremos da correlação e os outros dois são valores próximos de zero.

Fig. 8. Gráfico de dispersão das funções com correlações importantes



No entanto, para uma análise precisa dos dados, é importante verificar a presença de outliers nos preditores, já que essas exceções podem afetar os resultados da análise, mesmo que não tenham impacto na prática. Portanto, foram plotados diagramas de caixa (box plots) para destacar outliers interessantes.

Fig. 9. Box plot de preditores com outliers importantes



Através dos diagramas de caixa, é possível visualizar os dados de uma maneira diferente, identificando as influências de cada variável sobre as outras e possíveis relações entre os preditores.

E. Análise incondicional multivariada

À medida que o número de preditores aumenta, a necessidade de análises entre cada par de preditores cresce quadraticamente. Portanto, é essencial usar técnicas de análise multivariada que permitem a avaliação simultânea de várias variáveis. Essas técnicas exploram a redundância nas dimensões de dados de alta dimensionalidade, explicando-as por meio de combinações de outras variáveis.

Para realização desta análise, escolhemos a Análise de Componentes Principais (PCA), que é uma técnica de redução de dimensionalidade frequentemente usada para visualizar e compreender a estrutura dos dados em um espaço de menor dimensão. Dado um conjunto de dados $\mathcal{Y} = \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n\}$, $\mathbf{y}_i \in \mathbb{R}^D$, com média igual a 0, temos no nosso n observações e D preditores $\{p_1, p_2, \dots, p_D\}$. A partir disso, conseguimos definir a matriz de covariância sendo esta:

$$S = \frac{1}{n} \sum_{i=1}^n \mathbf{y}_i \mathbf{y}_i^T$$

Sendo $S \in \mathbb{R}^{D \times D}$. Cada termo de s_{ij} expressa a covariância entre p_i e p_j . Os componentes principais podem ser encontrados como sendo autovetores contidos na matriz S e as suas variâncias são iguais aos autovalores que estão a eles associados. Dessa forma, para maximizar a variância total dos dados, deve-se escolher os componentes que estejam associados aos maiores autovalores. A partir disso, podemos realizar a projeção dos dados originais sobre o espaço vetorial que tem como base os componentes principais selecionados.

Podemos também encontrar num conjunto de autovalores qualquer de S a contribuição do i -ésimo componente principal associado ao autovalor(λ_i), que pode ser calculado da seguinte maneira:

$$PC_i = \frac{\lambda_i}{\sum_{j=1}^D \lambda_j}$$

Tendo em vista que o conjunto de dados escolhido para realizar esse estudo não apresenta uma média igual a 0, precisamos, antes de calcular as componentes principais, escalonar os dados para que tenham média 0. Para tal problemática, utilizaremos a seguinte forma para realizar a transformação:

$$\tilde{y}_i = \frac{y_i - \mu}{\sigma} \quad (1)$$

Onde temos $\mu, \sigma \in \mathbb{R}^D$ representam, respectivamente, a média e o desvio padrão da base de dados utilizada. Feito isso, teremos, por fim, que o novo conjunto de observações terá média e desvio padrão igual a 0 e 1, nessa ordem.

Utilizando os valores transformados, podemos agora calcular os autovalores da matriz de covariância dos dados para descobrir qual a contribuição de cada componente principal no conjunto de dados. Aplicando isso, obtemos as figuras 10 e 11.

Fig. 10. Gráfico da influência das componentes principais na variância dos dados





Fig. 11. Gráfico da análise das componentes principais



Fazendo uso das duas primeiras componentes principais, realizamos uma projeção dos dados a partir das mesmas e obtemos como resultado a figura 11, na qual os pontos em rosa representam as observações da classe [1-29 Dias] e os pontos azuis a classe [29-365 Dias];

III. RESULTADOS

A. Resultados da análise incondicional monovariada

A análise monovariada incondicional oferece informações cruciais sobre as características individuais de cada preditor

no conjunto de dados (Tabela I). As medidas variam consideravelmente entre os preditores, revelando a diversidade do conjunto de dados.

As médias exibem uma ampla variação, refletindo as diferentes magnitudes e influências de cada atributo na resistência à compressão do concreto. Esta diversidade ressalta a importância de compreender a contribuição relativa de cada preditor.

O desvio padrão indica a dispersão dos dados em torno das médias. O preditor "Cimento" tem o maior desvio padrão, indicando maior variabilidade, enquanto o "Superplastificante" possui o menor desvio padrão, sugerindo maior proximidade da média.

A assimetria revela insights sobre a distribuição dos dados. A maioria dos preditores apresenta uma assimetria positiva, indicando inclinação à direita nas distribuições. "Idade" tem uma assimetria positiva acentuada, enquanto "Agregado Miúdo" mostra uma assimetria negativa leve. "Agregado Graúdo" possui uma assimetria negativa quase simétrica.

Esses resultados destacam a diversidade e complexidade dos dados, enfatizando a importância de considerar cada preditor cuidadosamente ao desenvolver modelos de previsão.

TABLE I
RESULTADOS OBTIDOS COM A ANÁLISE MONOVARIA DA INCONDICIONAL

Preditor (D)	μ_d	σ_d	γ_d
Cimento	281.17	104.51	0.51
Escória de Alto-Forno	73.90	86.28	0.80
Cinza Volante	54.19	64.00	0.54
Água	181.57	21.36	0.07
Superplastificante	6.20	5.97	0.91
Agregado Graúdo	972.92	77.75	-0.04
Agregado Miúdo	773.58	80.18	-0.25
Idade	45.66	63.17	3.27
Resistência à Compressão	35.82	16.71	0.42

Portanto, a análise monovariada incondicional, que inclui o conjunto de histogramas, médias, desvios padrão e assimetrias, revelou informações valiosas sobre o comportamento dos preditores no conjunto de dados. Isso contribuiu significativamente para uma compreensão mais profunda da relação entre esses atributos e a resistência à compressão do concreto.

B. Resultados da análise classe-condicional monovariada

Os resultados das medidas estatísticas obtidas para as classes de [1-29 Dias] e [29-365 Dias] estão disponibilizados nas Tabelas II e III.

Analisando os resultados obtidos, verificamos que, pelo fato do nosso conjunto de dados não possuir classes definidas e considerarmos uma componente como sendo a classe para o nosso dataset, a correlação entre os dados é bem baixa e ao condicionar as demais features com a idade do concreto, não é possível obter uma conclusão satisfatória do que as informações obtidas representam no nosso conjunto de dados.

Porém, mesmo havendo tal transtorno, ao analisarmos as informações dos resultados obtidos contidos nas tabelas II e III, podemos verificar que a maioria dos resultados são bem

próximos aos encontrados na tabela I, fato esse que estende a explicação dos resultados obtidos na análise incondicional monovariada e complementa a informação de que a separação das classes da forma que fizemos não produz uma conclusão precisa sobre o dataset manuseado.

TABLE II
RESULTADOS OBTIDOS COM A ANÁLISE MONOVARIADA
CLASSE-CONDICIONAL

Preditor (D)	μ_d	σ_d	γ_d
Cimento	276.09	105.07	0.54
Escória de Alto-Forno	77.94	86.46	0.73
Cinza Volante	56.08	64.61	0.50
Água	181.09	19.44	-0.11
Superplastificante	6.34	5.82	0.81
Agregado Graúdo	970.37	80.99	-0.04
Agregado Miúdo	773.43	75.67	-0.15
Idade	18.76	10.91	-0.43
Resistência à Compressão	31.04	15.23	0.65

TABLE III
RESULTADOS OBTIDOS COM A ANÁLISE MONOVARIADA
CLASSE-CONDICIONAL

Preditor (D)	μ_d	σ_d	γ_d
Cimento	294.70	101.96	0.47
Escória de Alto-Forno	63.12	79.32	0.99
Cinza Volante	49.13	62.15	0.65
Água	182.83	25.77	0.22
Superplastificante	5.85	6.35	1.13
Agregado Graúdo	979.70	68.06	0.09
Agregado Miúdo	773.96	91.25	-0.41
Idade	117.36	85.16	1.91
Resistência à Compressão	48.57	13.47	0.47

C. Resultados da análise incondicional bi-variada

Conforme foi apresentado na figura 6 e 7, conseguimos perceber a relação gráfica e os valores de correlação de todos os pares de preditores.

Dentre os gráficos apresentados, destacamos a relevante relação entre Água e Superplastificante, que exibe a maior correlação negativa, aproximadamente -0.66. Para aprofundar nessa relação, elaboramos um gráfico separado (Figura 8(a)). Este gráfico reforça a tendência já abordada na teoria, onde correlações negativas tendem a ser inversamente proporcionais, resultando em uma diminuição aproximadamente linear dos valores em alguns pontos.

Ademais, nos dados utilizados também encontramos um valor que é consideravelmente próximo de 1, no caso, a relação do Cimento e Resistência à Compressão, uma vez que a correlação é de 0.5, visualizamos que as variáveis crescem juntas, mantendo uma característica linear bem semelhante com o do exemplo anterior, sendo isso analisado na figura 8(b).

Como utilizamos dados com diversos preditores, é possível observar muitos tipos de relações entre nossas variáveis, inclusive valores que se relacionam, mas não de forma linear como os exemplos anteriores. A relação de Agregado Graúdo

e Idade possui uma correlação de valor 0, ou seja, não existe uma relação linear forte entre esses preditores, consequentemente não existindo linearidade entre os pontos no gráfico de dispersão 8(c).

Portanto, por meio da análise das relações entre os preditores, compreendemos a influência de cada variável na formulação do concreto, seja de maneira direta ou inversa, linear ou não. Destaca-se que o Cimento emerge como o principal preditor da Resistência à Compressão, com uma correlação positiva de 0.5. Isso significa que um aumento na quantidade de cimento está associado a um aumento na resistência, mesmo que essa relação não seja completamente linear.

Como mencionado anteriormente e ilustrado nas figuras 9, a verificação de outliers é essencial. Notamos alguns boxplots notáveis. Os primeiros (Figuras 9(b) e (c)) chamam a atenção por terem poucos ou nenhum outlier e intervalos consideravelmente amplos. Em contraste, outros boxplots (Figura 9(d)) estão em intervalos menores e apresentam um maior número de outliers.

Observamos outliers em algumas variáveis, que podem influenciar a correlação e exigir tratamento para melhorar a qualidade dos dados. No entanto, notamos que não há outliers no valor do cimento (Figura 9(a)), o que sugere que essa feature não requer pré-processamento.

D. Resultados da análise incondicional multivariada

Fazendo uma análise acerca da figura 10, podemos aferir que os dois primeiros componentes principais não descrevem muito bem a variância dos dados, pois representam apenas 46,94%. No entanto, na figura 11 conseguimos obter uma boa separação das classes [1-29 Dias] e [29-365 Dias]. é possível verificar através desse plot, analisando os loadings, que as variáveis que têm maior influência nele são a Água e o Superplastificante.

REFERENCES

- [1] Hongyu, K., Sandanielo, V. L. M., & de Oliveira Junior, G. J. (2016). Análise de componentes principais: resumo teórico, aplicação e interpretação. E&S Engineering and science, 5(1), 83-90.
- [2] James, Gareth, et al. An Introduction to Statistical Learning. 1st ed., PDF, Springer, 2013.
- [3] Kuhn, Max, and Kjell Johnson. Applied Predictive Modeling. Springer, 2018.
- [4] da Silva Bezerra, A. C., Campolina, B. M., & Paulino, M. T. (2007). RESISTÊNCIA À COMPRESSÃO DE CONCRETOS: UMA ANÁLISE COMPUTACIONAL.
- [5] Pinheiro, L. L. (2022). Uso de ferramentas de inteligência artificial para previsão de propriedades de resistência à compressão de concretos de alto desempenho e de ultra alto desempenho.
- [6] Camargo, M. V. D., & Ferrari, V. J. (2021). Resistência à compressão e módulo de elasticidade do concreto por meio de ensaios não destrutivos (END). Matéria (Rio de Janeiro), 26, e13047.
- [7] I-Cheng Yeh, "Modeling of strength of high performance concrete using artificial neural networks," Cement and Concrete Research, Vol. 28, No. 12, pp. 1797-1808 (1998)