

Modelos de Regressão para Previsão da Resistência do Concreto

1st João Victor Tavares Esteves

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
joaovtesteves2002@alu.ufc.br

2nd Manoel Guilherme Oliveira Ferreira

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
guiferreira29@alu.ufc.br

3rd Rodrigo da Silva Carvalho Maia

Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
rodrigomaia@alu.ufc.br

Resumo—Com o avanço tecnológico, a construção de modelos de previsão tornou-se essencial em diversas áreas. Este estudo explora a aplicação de técnicas de análise exploratória para compreender a distribuição e características de conjuntos de dados. Além disso, investigamos modelos de regressão linear convencional, regressão L2-penalizada, *Partial Least Squares* (PLS) e Modelo de Rede Neural para prever a resistência de compressão do concreto. A regressão linear ordinária se destacou nos testes, alcançando um coeficiente de determinação (R^2) de 79.1% e um RMSE (Root Mean Square Error) de 7.651.

Palavras-chave—Regressão Linear, Regressão Linear Penalizada, *Principal Component Regression*, *Partial Least Squares Regression*, Análise Exploratória, Métricas de Avaliação (RMSE e R^2), Validação Cruzada, Modelo de Rede Neural.

I. INTRODUÇÃO

Desde tempos imemoriais, a humanidade tem se esforçado para decifrar o futuro. Civilizações antigas, assim como as sociedades contemporâneas, empregavam uma variedade de técnicas para determinar, por exemplo, o momento certo para plantar uma safra específica em um solo específico. Essas previsões, mesmo nas eras mais antigas, eram fundamentadas em conjuntos de dados, por mais rudimentares que fossem, essenciais para antecipar o curso dos eventos. No entanto, à medida que a tecnologia e a ciência evoluíram, testemunhamos o surgimento de computadores poderosos capazes de processar vastos conjuntos de dados em questão de segundos, juntamente com modelos computacionais sofisticados. Estas ferramentas modernas tornaram a arte da previsão mais acessível do que nunca.

Nesse contexto, a capacidade de prever a resistência à compressão do concreto, uma propriedade crítica para engenheiros civis e arquitetos [3], tornou-se uma área de interesse particular. A precisão nessa previsão não apenas influencia o design e a durabilidade das estruturas, mas também desempenha um papel crucial na segurança das construções. Para realizar tais previsões de maneira confiável, é fundamental contar com conjuntos de dados robustos e modelos matemáticos avançados. No entanto, os dados brutos, por vezes, podem

ser enganosos, exigindo técnicas sofisticadas de processamento para extrair padrões significativos [1].

Neste cenário, a regressão linear emerge como uma ferramenta valiosa. Modelos de regressão linear são intrinsecamente poderosos [5], oferecendo insights profundamente interpretáveis sobre as relações entre variáveis. Eles não apenas possibilitam a previsão da resistência à compressão do concreto, mas também permitem uma compreensão mais profunda de como diferentes características impactam essa propriedade fundamental do material.

Além disso, assim como as gerações passadas observavam cuidadosamente o mundo ao seu redor para fazer previsões, os cientistas modernos observam atentamente os dados, utilizando métodos avançados para compreender melhor o comportamento do concreto sob compressão. Neste artigo, exploraremos diversas técnicas de regressão linear, desde os princípios básicos até abordagens avançadas, visando construir modelos precisos que nos permitam inferir a resistência à compressão do concreto. Para alcançar esse objetivo, examinaremos a importância do pré-processamento de dados, a identificação e tratamento de outliers [2], a seleção criteriosa de variáveis preditoras e a interpretação cuidadosa dos resultados.

Dentro deste contexto, adentramos no mundo complexo e fascinante da previsão da resistência à compressão do concreto [4], onde os métodos tradicionais se encontram com a vanguarda da ciência de dados. Ao explorarmos os meandros da regressão linear aplicada a este desafio, esperamos desvendar segredos que não apenas aprimorarão nossas técnicas de previsão, mas também ampliarão nossa compreensão da própria essência do concreto e sua capacidade de resistir às forças da compressão.

II. NOTAÇÕES

O conjunto de dados com N observações com D preditores está armazenado em uma matriz $\mathbf{X} \in \mathbb{R}^{N \times D}$, onde $\mathbf{X} = [x_1, \dots, x_N]^T$, $x_i \in \mathbb{R}^D$ e o conjunto das N observações

de uma variável dependente, a que queremos prever, está armazenado em uma matriz $\mathbf{Y} = [y_1, \dots, y_n]^T \in \mathbb{R}^N$. A saída do modelo preditivo referente a uma entrada x_i será denotada por $\hat{y}_i$ e definimos o resíduo, e_i , como sendo a diferença entre o valor real da variável dependente e o previsto pelo modelo.

$$e_i = y_i - \hat{y}_i \quad (1)$$

III. MÉTODOS

A. Métodos utilizados

1) *Análise Exploratória*: É crucial conduzir uma análise exploratória abrangente ao lidar com conjuntos de dados, pois essa prática é fundamental para construir modelos preditivos precisos. A compreensão das principais características dos dados é vital para qualquer análise estatística. Como é visto em literaturas sobre o tema, diversas técnicas de análise exploratória estão disponíveis, e a escolha depende dos objetivos específicos da investigação.

Neste contexto, este artigo emprega uma abordagem abrangente, incluindo análises univariadas e bivariadas. A análise univariada examina as características individuais das variáveis preditoras, proporcionando *insights* sobre suas distribuições e variabilidades. Por sua vez, a análise bivariada investiga as relações entre pares de variáveis, revelando possíveis associações ou padrões.

Além das análises mencionadas, também temos que fazer um pré-processamento dos dados. Durante esta etapa, são identificadas e tratadas assimetrias nos dados, bem como *outliers* que podem distorcer as análises subsequentes. Corrigir esses problemas potenciais é essencial para garantir a confiabilidade dos resultados obtidos com os modelos preditivos.

Portanto, a análise exploratória e o pré-processamento são etapas essenciais na preparação dos dados antes da construção dos modelos preditivos.

2) *Métricas de Avaliação*: Neste estudo, duas métricas principais foram adotadas para avaliar o desempenho do modelo preditivo. A primeira delas é a raiz do erro quadrático médio (*Root Mean Square Error* - RMSE), que representa a raiz quadrada da média das diferenças ao quadrado entre os valores reais (y_i) e os valores preditos ($\hat{y}_i$) (Equação 2). Ela oferece uma medida da precisão das previsões em relação aos dados reais, sendo calculada como:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2} \quad (2)$$

A segunda métrica empregada é o coeficiente de determinação (R^2), que é uma medida estatística que indica a proporção da variância em Y que pode ser explicada pela variância em X .

Essas métricas são essenciais para avaliar a precisão e a eficácia do modelo preditivo, fornecendo *insights* valiosos sobre o quão bem as previsões do modelo se alinham com os dados reais.

3) *Validação Cruzada*: Na abordagem tradicional de validação de modelo, o conjunto de dados é dividido em conjuntos de treino e teste. O modelo é treinado com o conjunto de treino e avaliado com o conjunto de teste. No entanto, essa abordagem pode levar a variações no desempenho do modelo devido à aleatoriedade na escolha dos dados de teste. A seleção arbitrária dos conjuntos de teste pode favorecer alguns modelos em detrimento de outros. Quanto maior o número de casos de teste, menor será o impacto dessa divisão aleatória.

Para superar a limitação da seleção aleatória dos *datasets* de treino e teste, a validação cruzada com k dobras é utilizada. Nesse método, o conjunto de treino é dividido em k subconjuntos. $k - 1$ desses subconjuntos são usados para treinar o modelo, enquanto o subconjunto restante é usado para calcular alguma métrica de desempenho, como o RMSE. Esse processo é repetido k vezes, variando apenas o subconjunto de validação em cada iteração e gerando k valores de RMSE. A avaliação gerada pela validação cruzada com k dobras, $CV_{(k)}$, é dada pela média desses valores.

4) *Regressão Linear Ordinária*: A regressão linear ordinária é uma técnica simples de previsão, presumindo uma relação linear entre as entradas (x_i) e as saídas (y_i) do conjunto de dados:

$$y_i = \beta_0 + \sum_{j=1}^D x_{ij} \beta_j$$

onde β_0 é a constante de interseção e β_j ($1 \leq j \leq D$) são coeficientes das variáveis de entrada. Os dados são divididos em conjuntos de treino e teste. No treino, os coeficientes são estimados usando o método dos mínimos quadrados, minimizando a soma dos quadrados dos resíduos (e_i). O modelo é então usado para prever saídas com base nos dados de teste, sendo avaliado por métricas como raiz quadrada do erro médio e coeficiente de determinação.

Apesar da simplicidade, a regressão linear ordinária tem limitações, como relações não-lineares e alta correlação entre variáveis de entrada. Técnicas de penalização foram desenvolvidas para melhorar a precisão do modelo, reduzindo certos coeficientes.

5) *Regressão Linear L2 - penalizada*: Também conhecida como regressão *Ridge*, este modelo aplica uma penalidade à soma dos erros quadrados (SSE) por meio de um parâmetro λ , conforme indicado na Equação 3.

$$SSE_{L2} = \sum_{i=1}^n e_i^2 + \lambda \sum_{j=1}^P \beta_j^2 \quad (3)$$

A finalidade dessa penalização é reduzir a variância do modelo de regressão linear simples, causada por correlações elevadas entre os preditores, mesmo com a inclusão de um viés (*bias*) no modelo. Isso pode resultar em valores de *RMSE* inferiores aos modelos não enviesados.

6) *Regressão PLS ou PCR*: PLS é uma técnica estatística multivariada que combina a regressão múltipla e a análise de componentes principais (PCA) para tratar situações com

multicolinearidade e alta dimensionalidade. Essa análise é utilizada como embasamento de alguns modelos de regressão, como o PCR e o PLS. O PCR é uma abordagem que integra a PCA com a regressão linear reduzindo a dimensionalidade dos dados e, em seguida, aplica uma regressão linear às componentes principais. A aplicação de ambas as técnicas é muito positiva quando há uma grande quantidade de preditores correlacionados, pois ajudam a resolver problemas de multicolinearidade e resultam em previsões mais precisas que modelos de regressão simples diante a problemática citada.

Utilizando PCA para obter $M < p$ componentes principais de uma matriz de observações $\mathbf{X}$, $Z_1, Z_2, \dots, Z_M$, podemos aplicar uma regressão linear ordinária considerando essas componentes como preditores. A previsão é formulada como:

$$\hat{y}_{(M)}^{pcr} = \hat{\theta}_0 + \sum_{i=1}^M \hat{\theta}_i Z_i$$

Esse método, que envolve a redução da dimensionalidade usando PCA e a aplicação de uma regressão linear nos dados transformados, é denominado como PCR.

No modelo PLS, inicialmente, é realizado o cálculo de um conjunto de variáveis que são combinações lineares dos preditores originais, o que se assemelha ao PCA. O que muda é que, no PLS, ocorre a maximização da covariância entre os preditores e a correlação entre os preditores e a variável de saída. Dessa forma, é gerado um conjunto de variáveis que proporciona boas previsões para a realização de uma regressão linear.

7) *Rede Neural para Regressão*: Existem muitas maneiras e aplicações possíveis para se utilizar uma rede neural com o intuito de analisar um conjunto de dados. Visando a construção de um modelo de rede neural para regressão, uma metodologia eficaz é a Regressão de Perceptron Multicamadas (MLP). O MLP é composto por múltiplas camadas de neurônios (também chamados de perceptrons) organizados em três tipos principais de camadas como:

- Camada de Entrada: contém os nós correspondentes às variáveis predictoras do conjunto de dados. Cada nó, nesta camada, representa um preditor.
- Camadas Ocultas: a regressão MLP pode ter uma ou mais camadas ocultas. Cada camada oculta consiste em um número de neurônios (ou nós) que aprendem representações intermediárias dos dados. A aprendizagem de padrões complexos ocorre nesta camada.
- Camada de Saída: contém um único nó no caso da regressão. O valor de saída deste nó é a previsão do modelo.

O processo de treinamento realizado por esse modelo em específico acontece, inicialmente, pela aplicação de pesos aleatórios na camada de entrada. Em seguida, ocorre o processo de *Forward Propagation*, que consiste na alimentação dos dados para a rede neural e os valores nas camadas ocultas e de saída são calculados através de funções de ativação aplicadas aos somatórios ponderados das entradas. A partir desses valores, são calculados os erros entre as previsões

da rede e os valores reais usando uma função de perda, como o *RSME*. Com base no erro, é acionado o processo de *Backpropagation*, que retorna o erro através da rede para ajustar os pesos. Algoritmos de otimização, como o do gradiente descendente, são usados nesse passo para minimizar a função de perda, de forma que os pesos são ajustados para diminuir o erro resultante do modelo. Esse procedimento é repetido de forma iterativa (por épocas), finalizando quando o modelo conseguir atingir um desempenho satisfatório ou quando o número máximo de épocas for alcançado.

B. Descrição do Dataset

O conjunto de dados que estamos usando, "Concrete Compressive Strength" [6], é composto por 1030 amostras de concreto, coletadas para medir a resistência a compressão. Cada amostra de concreto possui 9 componentes. Além disso, como nesse conjunto não temos classes propriamente ditas, resolvemos separar em subconjuntos de dados de acordo com a coluna "Age" que representa a idade do concreto da seguinte forma [1-29 dias], [29-365 dias]. Vale ressaltar que todas as características foram determinadas em laboratório, as sete primeiras características estão em kg por metro cúbico de mistura, a oitava em dias(1-365) e a nona em megapascals.

Seguem as nove componentes do conjunto de dados:

- 1) Cimento
- 2) Escória de Alto-Forno
- 3) Cinza Volante
- 4) Água
- 5) Superplastificante
- 6) Agregado Graúdo
- 7) Agregado Miúdo
- 8) Idade
- 9) Resistência à Compressão do Concreto

Os oito primeiros preditores são baseados em testes de laboratório como entrada e o último é baseado também em experimentos em laboratórios, porém como saída.

C. Análise Exploratória

Para iniciarmos nosso estudo, precisamos primeiramente realizar a análise exploratória dos dados, visando obter insights sobre o conteúdo que estamos manuseando, a fim de proporcionar melhor entendimento das características utilizadas posteriormente na modelagem dos modelos de regressão linear. Nosso dataset foi dividido em treino e teste, portanto, os procedimentos serão repetidos em ambas as partes.

Primeiramente faremos a verificação das principais características, sendo elas: média, desvio padrão, tamanho dos quartis, valor máximo e mínimo. Os cálculos foram executados em ambos conjuntos treino e teste, para os preditores e para a variável de saída.

A partir disso, fazemos uma análise monovariada, plotando os histogramas e avaliando seu skewness. Este processo será repetido após o pré-processamento de modo a visualizar o atenuamento das assimetrias após a aplicação da transformação logarítmica, mas primeiro iremos visualizar os boxplots de modo a verificar a presença de outliers em

nosso conjunto. Com isso, temos uma percepção mais apurada do comportamento de cada preditor, sendo assim podemos construir a matriz de correlação de modo a perceber como os preditores relacionam-se entre si.

Tendo em vista a análise anterior, foi notável a necessidade da realização de um pré-processamento nos dados antes de construir as regressões lineares. Sendo assim, a assimetria foi tratada por meio da transformação logarítmica.

Após a realização do pré-processamento, plotamos novamente os histogramas dos preditores, ambos teste e treino, a fim de verificar se sua transformação ocorreu de maneira satisfatória.

D. Modelo de Regressão Linear Ordinária

Para a construção do Modelo de Regressão Linear Ordinária, fizemos o treino com o conjunto de dados Xtrain após o pré-processamento e com o conjunto ytrain. Ademais, o teste foi feito com o conjunto de dados Xtest após o pré-processamento. Com isso, aplicamos a validação cruzada para obter um esquema de reamostragem, foi dado a opção de utilizar 5 ou 10 *folds*, em nosso caso utilizamos 10 *folds*. Além disso, foram utilizadas funções nativas da linguagem *python*, indicadas com a sigla 'py' na tabela posterior, com o intuito de comparar com as desenvolvidas manualmente. Os resultados obtidos podem ser vistos na Tabela I:

TABELA I
RESULTADOS DO TESTE COM OS MODELOS DE REGRESSÃO LINEAR ORDINÁRIA.

Modelo	RMSE	R ²
Ordinária sem validação cruzada	6.981	0.811
Ordinária sem validação cruzada(py)	9.797	0.628
Ordinária com validação cruzada de 10 dobras	7.651	0.791
Ordinária com validação cruzada de 10 dobras(py)	7.614	0.794

E. Modelo de Regressão Linear L2-penalizado

Os resultados da aplicação da técnica de regressão Ridge, também conhecida como regressão L2-penalizada, foram analisados para prever a resistência à compressão do concreto. Para este estudo, inicialmente, os dados brutos foram pré-processados.

Após o pré-processamento, foi realizada uma validação cruzada com 10 *folds* no conjunto de treinamento para determinar o valor ótimo do parâmetro de penalidade λ para a regressão Ridge. Os valores de λ testados variaram de 0.1 a 5000. O valor ótimo de λ , determinado pela validação cruzada, foi 0.5.

Usando este valor ótimo de λ , o modelo de regressão Ridge foi treinado novamente com todo o conjunto de treinamento. Em seguida, o modelo foi aplicado ao conjunto de teste para avaliar seu desempenho. Os resultados indicam que o modelo de regressão Ridge alcançou um Erro Quadrático Médio (RMSE) de aproximadamente 9.82 e um coeficiente de determinação (R^2) de aproximadamente 0.626 no conjunto de teste. Estes valores indicam que o modelo foi capaz de explicar

aproximadamente 62.6% da variabilidade na resistência à compressão do concreto no conjunto de teste.

Comparando esses resultados com a implementação do Ridge fornecida pela biblioteca Scikit-Learn, observamos uma consistência notável. A implementação personalizada e a implementação do Scikit-Learn produziram resultados muito semelhantes, validando a precisão do modelo de regressão Ridge nesta tarefa específica.

Esses resultados destacam a eficácia da regressão L2-penalizada na previsão da resistência à compressão do concreto, demonstrando sua capacidade de lidar com correlações entre variáveis preditoras e melhorar a generalização do modelo para novos dados.

Resultados na Tabela II.

TABELA II
MELHOR λ PARA CADA QUANTIDADE DE DOBRAS USADAS E RESULTADOS PARA AS MÉTRICAS ANALISADAS.

Modelo	Melhor λ	RMSE	R ²
Do zero	0.5	9.822	0.625
Funções do Python	0.5	9.805	0.626

F. Modelo de Regressão PLS OU PCR

Previamente, fizemos a escolha do modelo de regressão PLS para aplicar no conjunto de dados a qual estamos trabalhando e encontrarmos quantas componentes, M , deve-se utilizar. Após isso, aplicamos uma validação cruzada de 10 dobras, utilizando o conjunto de dados pré-processado, levando em consideração a alta correlação entre os preditores, haja vista que o modelo é robusto à multicolinearidade. Além disso, é calculado para cada valor de M , entre 1 e 40, o $RMSE$ e o R^2 .

Feita a implementação do PLS, considerando 10 dobras, obtemos como o melhor valor $M=7$. Os resultados para a melhor quantidade de componentes, para o $RMSE$ e para o R^2 estão contidos na Tabela III e também pode ser feita a exploração da análise do modelo na Figura 1.



TABELA III
MELHOR M PARA A QUANTIDADE DE 10 DOBRAS E RESULTADOS PARA AS MÉTRICAS ANALISADAS.

Nº de dobras	Melhor M	RMSE	R ²
10	7	9.792	0.628

G. Modelo de Rede Neural para Regressão

Analisando todos os métodos de análise estudados para aplicação de uma regressão linear, podemos perceber que existem dificuldades para os modelos quando se trata de capturar padrões não lineares nos dados. Haja vista isso, uma solução para tal problema é a implementação de uma Rede Neural para regressão, técnica também conhecida como Regressão Neural.

A Regressão Neural, antes de ser alimentada dos dados, exige a padronização dos mesmos para terem média 0 e desvio



padr o $\sigma=1$. A padroniza  o   feita para garantir que todas as vari veis tenham a mesma escala, o que   fundamental para o funcionamento adequado de redes neurais.

Feita a padroniza  o,   realizado o treinamento do modelo. Ap s treinar o modelo, ele   usado para fazer previs es no conjunto de teste e as previs es s o comparadas com as vari veis de resposta reais. O desempenho do modelo   avaliado usando m tricas como o $RMSE$ e R^2 . $RMSE$ mede a diferen a m dia entre as previs es e os valores reais, enquanto R^2 indica a propor  o da variabilidade na vari vel de resposta que   explicada pela Rede Neural.

Aplicando essas t cnicas, foram obtidos os valores apresentados na Tabela IV e na Figura 2, vis veis logo a seguir.

TABELA IV
MELHOR M PARA A QUANTIDADE DE 10 DOBRAS E RESULTADOS PARA AS M TRICAS ANALISADAS.

Modelo	RMSE	R^2
Regress�o Neural	5.679	0.875


IV. RESULTADOS

A. Resultados da An lise Explor t ria

Por meio da an lise dos dados, conseguimos obter as principais caracter sticas do conjunto, tais como m dia, desvio padr o e os valores dos quartis. Com isso, ao fazer o *plot* dos

histogramas conseguimos visualizar que alguns dos preditores possuem certa assimetria, como podemos ver na Figura 3

Fig. 3. Histogramas dos preditores antes do pr -processamento.




(a) Cimento s/ p s-processamento (b) Idade s/ p s-processamento

Podemos visualizar nas figuras acima uma assimetria para a direita, mais vis vel no *feature* de Idade, aplicando o pr -processamento para remover as assimetrias, podemos perceber a centraliza  o dos dados e obter valores mais adequados para a aplica  o dos modelos de regress o. Ao executar o *plot* dos mesmos preditores ap s o pr -processamento, podemos perceber certa mudan a de atribui  es, principalmente na Idade.

B. Resultados das Regress es

Ap s realizar a valida  o cruzada com 10 dobras, foram determinados os hiperpar metros que proporcionaram o melhor desempenho para os modelos de regress o, com $\lambda = 0.5$

Fig. 4. Histogramas dos preditores após o pré processamento.



(a) Cimento c/ pós-processamento (b) Idade s/ pós-processamento

para a regressão L2-penalizada e $M = 7$ para o modelo de Regressão PLS.

Em seguida, os três modelos preditivos foram treinados utilizando o conjunto de treino completo e avaliados usando o conjunto de teste, resultando nos seguintes resultados:

TABELA V
RESULTADOS OBTIDOS COM MODELOS DE REGRESSÃO

Modelo	RMSE	R^2
Regressão Linear Ordinária	7.651	0.791
Regressão L2-penalizada	9.822	0.625
Partial Least Squares	9.792	0.628
Regressão Neural	5.679	0.875

As discrepâncias nos valores de RMSE e R^2 entre os modelos podem ser explicadas pelas diferenças em suas abordagens.

A Regressão Linear Ordinária, por não impor penalizações aos coeficientes, tende a se ajustar muito bem aos dados de treino, especialmente quando há uma relação linear forte entre as variáveis preditoras e a variável de resposta. Isso resulta em um RMSE menor, indicando um bom ajuste aos dados de treino. Entretanto, esse modelo pode ser suscetível ao *overfitting* quando aplicado a novos dados, levando a uma possível discrepância nos dados de teste.

Por outro lado, a Regressão L2-penalizada (Ridge) e o modelo Partial Least Squares (PLS) introduzem penalidades nos coeficientes para evitar *overfitting*, especialmente quando há multicolinearidade entre as variáveis preditoras. A penalização limita o crescimento excessivo dos coeficientes, resultando em uma maior generalização para novos dados. Embora isso possa levar a um aumento no RMSE dos dados de treino, geralmente resulta em um desempenho melhor nos dados de teste ou validação, como indicado pelos valores de RMSE e R^2 .

Essas diferenças destacam a importância de considerar a complexidade do modelo e a correlação entre variáveis ao escolher um método de regressão, garantindo tanto o ajuste adequado aos dados de treino quanto a capacidade de generalização para dados não vistos.

Uma maneira possível, e eficiente, de lidar com a alta correlação entre variáveis preditoras é a aplicação de um modelo de rede neural para regressão. Tal método é conhecido como Regressão Neural. Redes neurais têm a capacidade intrínseca de aprender padrões complexos nos dados, incluindo

relações não-lineares e interações entre variáveis. Portanto, em muitos casos, redes neurais podem lidar bem com a multicolinearidade, fato esse que ocorreu com o conjunto de dados manuseado nesse estudo.

No entanto, não é garantido que uma rede neural resolverá todos os problemas de multicolinearidade. O impacto da multicolinearidade depende da complexidade dos padrões de dados e da relação entre as variáveis. Se a multicolinearidade for extrema, podem ocorrer problemas de estabilidade numérica durante o treinamento da rede neural, fato esse que pode prejudicar o desempenho do modelo.

REFERENCES

- [1] KUROKI JÚNIOR, G. H.; GOTTSCHALG-DUQUE, C.. Uma proposta de arquitetura da informação aplicada ao processamento de linguagem natural: contribuições da Ciência da Informação no pré-processamento de dados para treinamento e aprendizado de redes neurais artificiais. RDBCI: Revista Digital de Biblioteconomia e Ciência da Informação, v. 21, p. e023002, 2023.
- [2] Kuhn, Max, and Kjell Johnson. Applied Predictive Modeling. Springer, 2018.
- [3] da Silva Bezerra, A. C., Campolina, B. M., & Paulino, M. T. (2007). RESISTÊNCIA À COMPRESSÃO DE CONCRETOS: UMA ANÁLISE COMPUTACIONAL.
- [4] Pinheiro, L. L. (2022). Uso de ferramentas de inteligência artificial para previsão de propriedades de resistência à compressão de concretos de alto desempenho e de ultra alto desempenho.
- [5] Rodrigues, Sandra Cristina Antunes, & Ferrari, V. J. (2012). Modelo de Regressão Linear e suas Aplicações
- [6] I-Cheng Yeh, "Modeling of strength of high performance concrete using artificial neural networks," Cement and Concrete Research, Vol. 28, No. 12, pp. 1797-1808 (1998)