

Classificação Binária da Resistência à Compressão do Concreto

1st João Victor Tavares Esteves
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
joaovtesteves2002@alu.ufc.br

2nd Manoel Guilherme Oliveira Ferreira
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
guiferreira29@alu.ufc.br

3rd Rodrigo da Silva Carvalho Maia
Departamento de Engenharia de Teleinformática
Universidade Federal do Ceará
Fortaleza, Brazil
rodrigomaia@alu.ufc.br

Resumo—Este estudo apresenta uma análise comparativa de modelos de classificação lineares e não lineares aplicados à predição da resistência à compressão do concreto. Utilizando um conjunto de dados consistindo em características físicas e químicas do concreto, modelos de regressão logística, análise discriminante quadrática e k-vizinhos mais próximos foram treinados e avaliados. A performance foi medida através de acurácia, precisão e a curva ROC. Os resultados sugerem que modelos lineares, especificamente a regressão logística, podem competir favoravelmente com modelos não lineares, desafiando a suposição de que estruturas complexas são necessárias para este tipo de análise de dados.

Palavras-chave—Aprendizado de Máquina, Classificação Binária, Resistência à Compressão do Concreto, Regressão Logística, Análise Discriminante Quadrática, k-Vizinhos Mais Próximos, ROC.

I. INTRODUÇÃO

A resistência à compressão do concreto é uma propriedade crítica que define sua aplicabilidade em diversas estruturas de engenharia. Tradicionalmente, a classificação da qualidade do concreto é realizada por meio de testes padronizados que podem ser tanto onerosos quanto demorados. Com o avanço das técnicas de aprendizado de máquina, a modelagem preditiva surgiu como uma ferramenta poderosa para antecipar as propriedades do concreto a partir de sua composição e idade, possibilitando uma avaliação mais rápida e eficiente da qualidade do material [3].

Neste trabalho, investigamos a aplicação de modelos de classificação lineares e não lineares [4] na tarefa de prever a resistência à compressão do concreto, categorizando-a como 'Bom' ou 'Ruim' para uso na construção civil. Especificamente, comparamos o desempenho da regressão logística — um modelo linear — com métodos não lineares, incluindo a análise discriminante quadrática (QDA) e o k-vizinhos mais próximos (k-NN), em um conjunto de dados composto por variáveis preditoras representando a composição química e física do concreto.

A análise se concentrou na acurácia, precisão e na área sob a curva (AUC) da curva de característica de operação do receptor (ROC) para cada modelo [5], fornecendo *insights* sobre a capacidade de cada abordagem em classificar corretamente a resistência do concreto. Além disso, discutimos a relevância das estruturas não lineares em relação aos modelos lineares simples, abordando a questão de se a complexidade adicional dos modelos não lineares se traduz em um desempenho superior para este tipo de problema de classificação.

II. MÉTODOS

A. Descrição do Dataset

O conjunto de dados utilizado neste estudo [1] detalha a formulação do concreto e sua resistência à compressão após um período de cura. Composto por 1030 amostras, cada uma representa uma mistura de concreto única com as seguintes variáveis preditoras quantitativas:

- **Cimento (kg em uma mistura de m³):** Quantidade de cimento utilizada, sendo o principal ingrediente ativo na mistura do concreto.
- **Escória de Alto Forno (kg em uma mistura de m³):** Quantidade de subproduto da produção de ferro, que adiciona resistência e durabilidade ao produto final.
- **Cinzas Volantes (kg em uma mistura de m³):** Subproduto da queima de carvão em usinas elétricas, utilizado como aditivo para melhorar a trabalhabilidade do concreto fresco.
- **Água (kg em uma mistura de m³):** Volume de água, um componente essencial que reage quimicamente com o cimento.
- **Superplastificante (kg em uma mistura de m³):** Aditivo que aumenta a fluidez da mistura sem aumentar o conteúdo de água.
- **Agregado Grosso (kg em uma mistura de m³):** Pedras e cascalho usados para dar volume e resistência à mistura.

- **Agregado Fino (kg em uma mistura de m³):** Areia ou outro material fino que preenche os espaços entre o agregado grosso.
- **Idade (dias):** O número de dias que a amostra de concreto foi curada, um fator significativo que influencia a resistência final do concreto.

A variável de saída é a **Resistência à Compressão do Concreto (MPa)**: uma medida quantitativa da capacidade do concreto de resistir a cargas de compressão. Todas as variáveis preditoras são de natureza quantitativa e contínua, enquanto a variável de saída foi transformada em duas categorias baseadas no primeiro quartil da distribuição da resistência à compressão. A categoria 'Ruim' corresponde às amostras com resistência abaixo do primeiro quartil, enquanto a categoria 'Bom' engloba aquelas com resistência acima ou igual a esse limiar.

B. Métodos utilizados

1) **Métricas de Avaliação:** Para uma avaliação abrangente do modelo de classificação, foram utilizadas as seguintes métricas:

- **Matriz de Confusão:** Uma tabela (matriz 2x2) que categoriza as previsões do modelo em comparação com os valores reais. Os elementos da matriz são definidos como:
 - **Verdadeiro Positivo (VP):** Número de amostras corretamente classificadas como pertencentes à classe positiva.
 - **Falso Negativo (FN):** Número de amostras da classe positiva incorretamente classificadas como pertencentes à classe negativa.
 - **Falso Positivo (FP):** Número de amostras da classe negativa incorretamente classificadas como pertencentes à classe positiva.
 - **Verdadeiro Negativo (VN):** Número de amostras corretamente classificadas como não pertencentes à classe positiva.

TABELA I
EXEMPLO DE MATRIZ DE CONFUSÃO

	Predito Positivo	Predito Negativo
Real Positivo	VP	FN
Real Negativo	FP	VN

- **Acurácia:** A proporção de previsões corretas do total de casos, considerando tanto as classificações positivas quanto as negativas.

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (1)$$

- **Precisão:** A proporção de previsões positivas corretas em relação ao total de previsões positivas feitas pelo modelo.

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2)$$

- **Sensibilidade** (ou Taxa de Verdadeiro Positivo): A proporção de casos positivos reais que foram identificados corretamente pelo modelo.

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad (3)$$

- **Especificidade** (ou Taxa de Verdadeiro Negativo): A proporção de casos negativos reais que foram identificados corretamente pelo modelo.

$$\text{Especificidade} = \frac{VN}{VN + FP} \quad (4)$$

- **AUC - Área sob a Curva ROC:** Uma medida de desempenho global do modelo, que considera a variação da sensibilidade e especificidade para diferentes limiares de classificação. A proximidade das AUCs ao valor máximo de 1.0 reflete a alta capacidade de todos os modelos testados de discriminar entre as classes 'Bom' e 'Ruim'.

2) **Validação Cruzada:** Para garantir que os modelos são generalizáveis e não estão sobreajustados (overfitting) a um subconjunto específico dos dados, foi empregada a técnica de validação cruzada. A validação cruzada *k-fold* particiona o conjunto de dados em *k* subconjuntos mutuamente exclusivos, treina o modelo em *k-1* subconjuntos e avalia o desempenho no subconjunto restante. Este processo é repetido *k* vezes, com cada subconjunto sendo utilizado uma vez como conjunto de teste, como vimos em [2].

3) **Regressão Logística:** A regressão logística é uma técnica estatística utilizada para modelar a probabilidade de uma variável dependente binária. O modelo é obtido através da seguinte função logística:

$$p(y = 1) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \dots + \beta_n x_n)}} \quad (5)$$

onde $p(y = 1)$ é a probabilidade da amostra pertencer à classe 1, e é a base do logaritmo natural, β_0 é o intercepto do modelo, também conhecido como viés, que representa a *log-odds* de uma amostra pertencer à classe 1 quando todas as variáveis preditoras são iguais a zero. Os coeficientes $\beta_1, \dots, \beta_n$ são os parâmetros do modelo que quantificam o efeito de cada variável preditora $x_1, \dots, x_n$ na *log-odds* da amostra pertencer à classe 1. Esses coeficientes são estimados durante o processo de treinamento do modelo e indicam a direção e a magnitude da associação entre cada preditor e a resposta.

Log-odds, ou logaritmo de chances, é uma medida que descreve o logaritmo natural da razão de chances (*odds*) de um evento ocorrer. As chances, ou *odds*, são definidas como a razão entre a probabilidade do evento ocorrer e a probabilidade de não ocorrer. Matematicamente, se p é a probabilidade do evento, as chances são $\frac{p}{1-p}$, e as *log-odds* são o logaritmo natural dessa razão:

$$\log\left(\frac{p}{1-p}\right) \quad (6)$$

Na regressão logística, as *log-odds* de uma variável dependente binária y sendo igual a 1 são modeladas como uma

função linear das variáveis preditoras. Assim, as *log-odds* são transformadas de volta para a escala de probabilidade (entre 0 e 1) por meio da função logística, permitindo que o modelo estime a probabilidade $p(y = 1)$ a partir dos preditores.

4) *Análise Quadrática Discriminante*: A Análise Discriminante Quadrática (QDA) é uma técnica estatística que assume que as medidas preditoras para cada classe são distribuídas segundo uma distribuição Gaussiana (ou Normal). Para a classificação, a QDA calcula a probabilidade condicional de uma observação pertencer a cada classe, dada a observação em si. Esta probabilidade é modelada pela função de densidade de probabilidade (fdp) da distribuição normal multivariada, que é dada por:

$$p(x|y = k) = \frac{1}{(2\pi)^{n/2} |\Sigma_k|^{1/2}} e^{-\frac{1}{2}(x - \mu_k)' \Sigma_k^{-1} (x - \mu_k)} \quad (7)$$

Aqui, $p(x|y = k)$ denota a probabilidade condicional da observação x pertencer à classe k . O vetor μ_k representa o vetor de médias das variáveis preditoras para a classe k , e Σ_k é a matriz de covariância associada à classe k , que captura a variação e a correlação entre as variáveis preditoras dentro dessa classe. O termo $(2\pi)^{n/2}$ é um fator de normalização decorrente da forma da distribuição normal multivariada, onde n é o número de variáveis preditoras. O determinante da matriz de covariância, $|\Sigma_k|$, ajusta a amplitude da PDF (Função de Densidade de Probabilidade) com base na variação dos dados: matrizes de covariância maiores levam a densidades mais espalhadas. O expoente $\exp$ é a função exponencial, e o termo $(x - \mu_k)' \Sigma_k^{-1} (x - \mu_k)$ é uma medida de distância quadrática de Mahalanobis, que pondera a distância entre a observação x e o vetor de média μ_k pela matriz de covariância Σ_k , permitindo que a distância seja medida de forma apropriada no espaço onde as variáveis preditoras estão correlacionadas.

5) *K-nearest neighbors*: O algoritmo dos k -vizinhos mais próximos (k-NN) é um método de classificação não-paramétrico e baseado em instância. Para uma amostra de teste dada, o k-NN identifica os k pontos mais próximos no conjunto de treinamento e atribui a classe com base na votação majoritária dos vizinhos. A distância entre as amostras no espaço de características é um aspecto crítico deste algoritmo e é frequentemente calculada usando a distância Euclidiana. A fórmula da distância Euclidiana entre dois pontos, x_i e x_j , em um espaço de características n -dimensional é dada por:

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2} \quad (8)$$

Nesta equação, $d(x_i, x_j)$ representa a distância Euclidiana entre os pontos x_i e x_j , que são vetores de características no espaço n -dimensional. Cada x_{ik} e x_{jk} são os valores da k -ésima característica (ou dimensão) dos pontos x_i e x_j , respectivamente. A soma é calculada sobre todas as n características, e a raiz quadrada é aplicada para retornar a distância Euclidiana final entre os pontos. O algoritmo k-NN utiliza essa distância para identificar os k vizinhos mais

próximos e realizar a classificação com base nos rótulos de classe desses vizinhos.

C. Pré-Processamento

O pré-processamento, como foi discutido em [2], é uma etapa crucial na preparação de dados para análises de aprendizado de máquina, garantindo que os modelos de classificação funcionem com eficácia. No contexto deste estudo, o pré-processamento dos dados envolveu algumas etapas essenciais descritas a seguir:

- **Limpeza de Dados**: Inicialmente, os dados foram inspecionados para identificar e corrigir quaisquer inconsistências, como valores ausentes ou anômalos. Para este conjunto de dados, nenhuma anomalia foi encontrada, permitindo que prosseguíssemos sem a necessidade de etapas adicionais de limpeza.
- **Normalização e Padronização**: Antes da modelagem, as variáveis preditoras foram padronizadas. A padronização é um processo que transforma os dados para que tenham uma média (μ) de zero e um desvio padrão (σ) de um. Este procedimento é crucial para algoritmos sensíveis à escala das variáveis, como o k-NN. A padronização ajuda a garantir que cada característica contribua igualmente para a distância calculada entre os pontos no espaço de características. A transformação padrão aplicada aos dados é expressa pela seguinte fórmula:

$$x' = \frac{x - \mu}{\sigma} \quad (9)$$

onde x representa o valor original da característica, μ é a média dos valores da característica em todo o conjunto de treinamento, e σ é o desvio padrão da característica. A variável padronizada x' resultante possui uma média de zero, o que significa que a característica está centralizada em torno da origem, e uma variância unitária, o que implica que a escala da característica é normalizada.

- **Transformação da Variável de Saída**: A variável de saída, originalmente uma medida contínua da resistência à compressão do concreto, foi convertida em uma variável binária. As amostras com resistência à compressão abaixo do primeiro quartil foram classificadas como 'Ruim', enquanto as demais foram classificadas como 'Bom'. Esta binarização permite que os modelos de classificação prevejam uma das duas categorias distintas.

Após o pré-processamento, o conjunto de dados foi dividido em subconjuntos de treino e teste, mantendo uma proporção de 80% para treino e 20% para teste. A divisão foi feita de forma estratificada para preservar a proporção das classes em ambos os subconjuntos.

D. Modelo de Regressão Logística

O modelo de regressão logística foi implementado para estimar a probabilidade de que a resistência à compressão do concreto seja classificada como 'Bom' ou 'Ruim'. O modelo usa a função logística para mapear a combinação linear das características de entrada para um intervalo de probabilidade entre 0 e 1.

TABELA II
DESEMPENHO DO MODELO DE REGRESSÃO LOGÍSTICA

Modelo	Acurácia	Precisão
Regressão Logística	90.78%	94.16%

A matriz de confusão para o modelo de regressão logística é apresentada na Tabela III. Esta tabela ilustra a quantidade de previsões corretas e incorretas feitas pelo modelo.

TABELA III
MATRIZ DE CONFUSÃO PARA O MODELO DE REGRESSÃO LOGÍSTICA

	Predito 'Bom'	Predito 'Ruim'
Real 'Bom'	145	10
Real 'Ruim'	9	42

Os resultados da Tabela II indicam que o modelo de regressão logística teve um bom desempenho, com uma acurácia de 90.78% e uma precisão de 94.16%. A sensibilidade e especificidade do modelo podem ser inferidas a partir da matriz de confusão. Com um número maior de verdadeiros positivos e verdadeiros negativos em comparação com os falsos negativos e falsos positivos, o modelo mostrou uma capacidade robusta de classificação para ambas as categorias de resistência à compressão do concreto.

E. Modelo de Análise Quadrática Discriminante

A Análise Quadrática Discriminante (QDA) é um classificador estatístico que considera as variações de covariância entre as classes. O QDA estima a probabilidade de uma dada amostra pertencer a determinada classe, assumindo que as distribuições condicionais das características são gaussianas.

TABELA IV
DESEMPENHO DO MODELO QDA

Modelo	Acurácia	Precisão
Análise Quadrática Discriminante	85.44%	97.71%

A Tabela V mostra a matriz de confusão para o modelo QDA, detalhando as previsões corretas e incorretas para cada classe.

TABELA V
MATRIZ DE CONFUSÃO PARA O MODELO QDA

	Predito 'Bom'	Predito 'Ruim'
Real 'Bom'	128	27
Real 'Ruim'	3	48

Os resultados Tabela IV obtidos pelo modelo QDA demonstram uma alta precisão de 97.71%, sugerindo que, quando o modelo prevê a classe 'Bom', ele está correto na maioria das vezes. A acurácia de 85.44% também é relativamente alta, mas inferior à obtida pelo modelo de regressão logística. A quantidade de falsos positivos (27) é maior em comparação com o modelo de regressão logística, o que pode indicar uma tendência do QDA em favor da classe 'Bom'. A robustez desse modelo pode ser influenciada pela suposição de normalidade e pela variação de covariância entre as classes.

F. Modelo de K-vizinhos mais próximos

O modelo k-vizinhos mais próximos (k-NN) é um método de aprendizado de máquina baseado em instâncias, que classifica novas amostras com base na maioria dos votos da quantidade 'k' de vizinhos mais próximos.

TABELA VI
DESEMPENHO DO MODELO K-NN

Modelo	Acurácia	Precisão
k-NN	90.29%	92.99%

A matriz de confusão para o modelo k-NN é apresentada na Tabela VII, fornecendo uma visão detalhada das previsões corretas e incorretas.

TABELA VII
MATRIZ DE CONFUSÃO PARA O MODELO K-NN

	Predito 'Bom'	Predito 'Ruim'
Real 'Bom'	146	9
Real 'Ruim'	11	40

Na Tabela VI, com uma acurácia de 90.29% e uma precisão de 92.99%, o modelo k-NN demonstrou ser muito eficaz na classificação da resistência à compressão do concreto. Os resultados indicam que o k-NN, mesmo sendo um algoritmo simples que não faz suposições sobre a distribuição dos dados, pode alcançar um desempenho comparável aos modelos mais sofisticados se aplicado aos conjuntos de dados propícios. A escolha do número de vizinhos (k) é crucial para o desempenho do modelo e foi determinada através de validação cruzada para evitar o sobreajuste.

O sobreajuste (*overfitting*) é um fenômeno comum que ocorre quando um modelo é excessivamente complexo e aprende tanto os padrões quanto o ruído nos dados de treinamento. Como resultado, o modelo se torna altamente especializado nos dados de treinamento e perde a capacidade de generalizar para novos dados não vistos anteriormente.

III. RESULTADOS

A. Resultados dos modelos de classificação

Os modelos de Regressão Logística, Análise Quadrática Discriminante e k-Vizinhos Mais Próximos foram avaliados com base nas métricas de acurácia, precisão e a curva ROC. A Tabela VIII resume o desempenho de cada um dos modelos.

TABELA VIII
COMPARAÇÃO DE DESEMPENHO DOS MODELOS DE CLASSIFICAÇÃO

Modelo	Acurácia	Precisão	AUC
Regressão Logística	90.78%	94.16%	0.9667
Análise Quadrática Discriminante	85.44%	97.71%	0.9607
k-NN	90.29%	92.99%	0.9526

Além disso, a Figura 1 ilustra a curva ROC para os três modelos, destacando a capacidade de cada modelo de distinguir entre as classes 'Bom' e 'Ruim'.




Fig. 1. Curva ROC dos Modelos de Classificação

A Regressão Logística apresentou um desempenho interessante, com uma acurácia de 90.78% e uma boa precisão de 94.16%, corroborada por uma AUC de 0.9667. Estes resultados destacam a capacidade do modelo de Regressão Logística de fazer previsões confiáveis e distinguir eficazmente entre as categorias 'Bom' e 'Ruim'.

A Análise Quadrática Discriminante seguiu o padrão de qualidade, com uma acurácia de 85.44%. No entanto, alcançou a maior precisão entre os três modelos, com 97.71%, sugerindo que, quando o modelo QDA prediz uma instância como 'Bom', esta predição é confiável. A AUC de 0.9607 é comparável à da Regressão Logística, o que indica que o QDA também é eficiente na classificação das classes do nosso estudo.

O modelo k-NN obteve resultados ligeiramente inferiores, com uma acurácia de 90.29% e uma precisão de 92.99%, mas ainda assim demonstrou ser robusto o suficiente com uma AUC de 0.9526. Este desempenho reforça o k-NN como uma opção válida para a classificação neste contexto.

Em suma, todos os modelos exibiram desempenho notável, com a Regressão Logística se destacando ligeiramente em termos de acurácia e AUC. A alta precisão do QDA também se destaca, especialmente em aplicações onde falsos positivos são críticos. Por fim, o k-NN provou ser competitivo, validando sua aplicação como uma abordagem confiável para a classificação binária neste estudo.

Em cenários práticos, a seleção do modelo também pode ser influenciada por considerações específicas do domínio, como o custo de diferentes tipos de erros de classificação.

REFERENCES

- [1] I-Cheng Yeh, "Modeling of strength of high performance concrete using artificial neural networks," *Cement and Concrete Research*, Vol. 28, No. 12, pp. 1797-1808 (1998)
- [2] Esteves, João Victor T., Ferreira, Manoel Guilherme O., Maia, Rodrigo S. C. (2023). *Modelos de Regressão para Previsão da Resistência do Concreto*.
- [3] Pinheiro, L. L. (2022). *Uso de ferramentas de inteligência artificial para previsão de propriedades de resistência à compressão de concretos de alto desempenho e de ultra alto desempenho*
- [4] Kuhn, Max, and Kjell Johnson. *Applied Predictive Modeling*. Springer, 2018.
- [5] James, Gareth, et al. *An Introduction to Statistical Learning*. 1st ed., PDF, Springer, 2013.